



中华人民共和国国家标准

GB/T 43389—2023

市场、民意和社会调查 数据分析方法

Market, opinion and social research—Data analysis methods

2023-11-27 发布

2023-11-27 实施

国家市场监督管理总局
国家标准化管理委员会 发布

目 次

前言 I

1 范围 1

2 规范性引用文件 1

3 术语和定义 1

4 调查数据预处理 2

 4.1 概述 2

 4.2 一致性检查 2

 4.3 缺失值处理 2

 4.4 异常值诊断与处理 3

 4.5 变量转换 3

 4.6 量表转换 3

5 调查数据的分析方法 3

 5.1 概述 3

 5.2 描述统计分析 3

 5.3 推论统计分析 3

 5.4 应用示例 3

参考文献..... 6

前 言

本文件按 GB/T 1.1—2020《标准化工作导则 第 1 部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由全国市场、民意和社会调查标准化技术委员会(SAC/TC 320)提出并归口。

本文件起草单位：中国标准化研究院、宜宾学院、广州云检测科学研究院有限公司、四川省产品质量监督检验检测院、绍兴湖瑞纺织有限公司、西安正建工程咨询有限公司、泸州老窖股份有限公司、浙江省产品与工程标准化协会、吉林省格远市场调研咨询有限公司、山东及时雨建材科技有限公司、广东省江门市质量技术监督标准与编码所、浙江省长三角标准技术研究院、中国计量大学、《中国城市报》社有限公司。

本文件主要起草人：许应成、华春翔、周晓群、朱盛艳、马振、张风格、冯卫、宁秀丽、张欣亮、周岭、赵位、张文平、廖源、许文倩、曹良克、吴倩、李莹、柳青、王双、陆小伟、藤君芳、范志平、邓铭庭、朱培武、蒙肇芸、郭新峰、杜英姿、常亮。

市场、民意和社会调查 数据分析方法

1 范围

本文件描述了市场、民意和社会调查中常见的数据分析方法,包括调查数据预处理及分析方法。
本文件适用于开展市场、民意和社会调查数据分析活动。

2 规范性引用文件



本文件没有规范性引用文件。

3 术语和定义

下列术语和定义适用于本文件。

3.1

调查 research

基于特定目的,按照一定规范收集、整理信息,进行分析和呈现的过程。

注: research 在实际应用中也称为“研究”或“调研”。相对 survey 而言 research 还包含了分析的过程。

[来源:GB/T 26315—2010,3.1]

3.2

总体 population

由所关注的全部个体组成的集合。

[来源:GB/T 26315—2010,5.2.1]

3.3

样本 sample

从总体中抽取的抽样单元构成的集合。

[来源:GB/T 26315—2010,5.2.6]

3.4

统计量 statistic

由随机变量完全确定的函数。

[来源:GB/T 3358.1—2009,1.8]

3.5

样本中位数 sample median

有序样本中处于中间位置的数值。

注:如果样本数据量为偶数,则为中间两个数值的平均值。

[来源:GB/T 3358.1—2009,1.13,有修改]

3.6

样本均值 sample mean

平均数 average

算术平均值 arithmetic mean

一组数据之和除以数据的总个数所得的值。

[来源:GB/T 3358.1—2009,1.15,有修改]

3.7

样本方差 **sample variance**

一组数据中每个数据值与该组数据的算术平均数之差的平方和除以样本数据的总个数减 1 所得的值。

[来源:GB/T 3358.1—2009,1.16,有修改]

3.8

样本标准差 **sample standard deviation**

样本方差的非负平方根。

[来源:GB/T 3358.1—2009,1.17]

3.9

频数 **frequency**

给定类(组)中,特定事件发生的次数或观测值的个数。

[来源:GB/T 3358.1—2009,1.59]

3.10

频率 **relative frequency**

用事件或者观测值发生的总数目除以频数所得的值。

[来源:GB/T 3358.1—2009,1.64,有修改]

3.11

概率 **probability**

赋予事件闭区间 $[0,1]$ 中的一个实数。

[来源:GB/T 3358.1—2009,2.5]

3.12

定性数据 **qualitative data**

定性变量的观测结果。

注:可分为分类数据和定序数据。



3.13

定量数据 **quantitative data**

定量变量的取值结果。

4 调查数据预处理

4.1 概述

调查数据预处理包括一致性检查、缺失值处理、异常值诊断与处理、变量转换和量表转换等。

4.2 一致性检查

主要包括变量的取值是否超出合理范围、有无逻辑错误及有无极端值。

4.3 缺失值处理

缺失值处理方法包括但不限于以下几个方面。

- a) 删除缺失值:如果缺失值的比例较小且对整体数据影响不大,可以直接删除包含缺失值的样本或属性。
- b) 插补缺失值:如果缺失值的比例较大或对整体数据影响较大,可以使用插补方法填充缺失值。

常见的插补方法包括均值插补、中位数插补、众数插补、回归插补、随机插补等。

- c) 使用特殊值填充:对于某些特定的缺失值,可以使用特殊值(如 0 或 -1)进行填充,表示该值缺失。
- d) 使用插值方法填充:对于时间序列数据或空间数据,可以使用插值方法(如线性插值、样条插值、Kriging 插值等)进行填充。
- e) 使用机器学习算法预测填充:对于缺失值较多的情况,可使用机器学习算法(如随机森林、支持向量机等)进行预测填充。

4.4 异常值诊断与处理

一般首先采用统计分布法、回归诊断法对异常值进行诊断,以及采用删除法、缩尾法、变换变量、降低异常值权数、插补法等处理异常值。

4.5 变量转换

根据数据分析的需要,在分析之前宜对现有的变量进行一定的修改或生成新的变量,可采用变量重新定义、变量转换、定类变量转换为 0-1 变量等方法。

4.6 量表转换

为保证数据的可比性,便于进行数据分析,某些场景下需要做一些量表的转换,可采用标准化变换、规格化变换等方法。

5 调查数据的分析方法

5.1 概述

市场、民意和社会调查数据分析方法可分为描述统计分析和推论统计分析。

5.2 描述统计分析

将数据以表格、图形或数值形式表现出来,着重于对数量水平或其他特征的描述,可通过某具体指标反映某一方面的特征,也能通过若干变量描述它们的相互关系,其结果重在数量描述,但不具有推断性质。

5.3 推论统计分析



通过样本推断总体,这类方法对数据的收集方法、变量的选择、测度的决定、资料的空间时间范围有严格的限制,宜符合严格的假设条件,其结果不仅可用于描述数量关系,还可以推断总体,进行预测、揭示原因以及检验理论等。

5.4 应用示例

5.4.1 概述

描述性统计分析适用于能收集到定量数据的几乎所有领域,它能为市场、民意和社会调查提供多方面的信息分析。推论统计分析使用样本数据来进行推断,并从中得出关于总体的结论,有助于在数据不够丰富的条件下为市场、民意和社会调查分析提供更多的支持。如表 1 所示。

表 1 调查数据分析方法示例

类型	基本性质	应用案例	适用的分析方法	
			单变量统计方法	多变量统计方法
定性数据	表明对象或其类别的数字	性别、品牌、商店等	比例、众数等	二项式检验等
	表示对象的相对位置，但不能表示差异大小的数字	偏好排序、在市场中的位次、社会分层等	比例、众数、中位数等	顺序相关系数、弗里德曼检验、方差分析等
定量数据	可以分类、排序、比较对象间的差异	态度、年龄、收入、成本、销售量、市场份额等	中位数、全距、均值等	相关系数、 t 检验、方差分析、回归、因子分析、结构方程、结合分析等

5.4.2 描述性统计分析示例

5.4.2.1 平均值

计算数据集中数值的平均值，可用于了解数据的中心趋势。例如，计算一组学生的考试成绩平均分，以评估整体表现水平。

5.4.2.2 中位数

计算数据集中数值的中间值，可用于了解数据的中心位置。例如，计算一组员工的薪资中位数，以了解工资分布的中间水平。

5.4.2.3 标准差

测量数据集中数值的离散程度，反映数据的变异程度。例如，在市场调研中，计算产品销售量的标准差可以评估销售数据的波动性。

5.4.2.4 频数分布表

将数据分组并计算每个组别中的观察频数，用于了解数据的分布情况。例如，制作一个年龄组别的频数分布表，以了解调查样本的年龄分布情况。

5.4.2.5 百分比

计算数据在总体中的百分比，用于描述某个类别在整体中的相对比例。例如，计算产品市场份额的百分比，以衡量产品在市场上的占有率。

5.4.2.6 全距

确定数据集中的最大和最小数值差值，以了解数据的范围。例如，计算某地区气温数据的最高和最低值差值，以描述气候的变化情况。

5.4.2.7 百分位数

计算数据集中特定百分比处的数值，可用于了解数据集的分位数分布。例如，计算一组学生的分数

在 75% 百分位数处的值,以确定高分学生的水平。

5.4.3 推论统计分析示例

5.4.3.1 配对 t 检验

用于比较同一组观察值在不同条件下的均值差异是否显著。例如,通过配对 t 检验来评估某种治疗方法前后患者血压的变化。

5.4.3.2 非参数检验

用于比较数据集的分布或中位数等非参数统计量的差异是否显著。例如,使用非参数检验比较两组样本的中位数差异。

5.4.3.3 多重比较

在进行多组比较时,采用修正方法来控制因多次比较而产生的错误率。例如,在进行多个广告渠道的效果比较时,使用多重比较方法进行比较。

5.4.3.4 方差分析的协变量

在进行方差分析时,考虑一个或多个协变量对因变量的影响。例如,在比较不同教育水平学生的成绩时控制年龄的影响。

5.4.3.5 非线性回归

用于建立自变量和因变量之间的非线性关系模型。例如,使用非线性回归分析来拟合一组企业发展曲线数据,以了解企业的发展过程。

5.4.3.6 时间序列分析

用于分析时间序列数据的趋势、季节性和周期性等特征。例如,在金融领域,使用时间序列分析来预测股票价格的未来走势。

5.4.3.7 因子分析

用于探索观测变量之间的共同变异,并将其归纳为更少的潜在因子。例如,在市场研究中,使用因子分析来识别潜在的消费者行为维度。



参 考 文 献

- [1] GB/T 3358.1—2009 统计学词汇及符号 第1部分：一般统计术语与用于概率的术语
 - [2] GB/T 26315—2010 市场、民意和社会调查 术语
 - [3] GB/T 26316—2010 市场、民意和社会调查 服务要求
-



